Artículo científico

Cámara de Seguridad Sanitaria con Inteligencia Artificial

Sanitary Security Camera with AI

Câmara de segurança sanitária com IA



Luis Mateo Aguirre Soliz

Universidad Privada Católica Boliviana

Resumen

El objetivo de la investigación fue desarrollar y evaluar un prototipo de cámara de seguridad sanitaria que, mediante inteligencia artificial, identifica posturas de riesgo, como la caída con inmovilidad en el piso o una postura de peligro en la cama, para activar una condición de alerta. Se realizó una investigación cuantitativa de desarrollo tecnológico aplicado: se entrenó un clasificador de pose en Teachable Machine con cuatro clases (normal, caída e inmovilidad, cama normal y cama de peligro) con imágenes de un conjunto de datos público, y se integró en una aplicación local que ejecuta el modelo en el navegador y aplica reglas de confianza superior a 0,95 y persistencia del peligro durante 15 segundos. El análisis usó imágenes no vistas en el entrenamiento, mediante matriz de confusión, sensibilidad, especificidad, precisión y medida F1. Los resultados muestran que el sistema opera con cámara, imágenes y videos, y que

la decisión de alerta alcanzó una sensibilidad de 95% y una especificidad de 96.4% en 625 imágenes. En conclusión, el prototipo funciona como producto mínimo viable, con alcance limitado a la clasificación de posturas y a una alerta local sin conexión externa.
Palabras clave: inteligencia artificial, seguridad, salud, accidentes.

Abstract

The objective of the research was to develop and evaluate a sanitary security camera prototype that uses artificial intelligence to identify risk postures, such as a fall followed by immobility on the floor or a dangerous posture in bed, in order to trigger an alert condition. A quantitative, applied technological development study was conducted: a pose classifier was trained in Teachable Machine with four classes (normal, fall and immobility, normal bed, and dangerous bed) using images from a public dataset, and it was integrated into a local application that runs the model in the browser and applies rules of confidence above 0.95 and danger persistence for 15 seconds. The analysis used images not seen in training, through a confusion matrix, sensitivity, specificity, precision, and F1 score. The results show that the system works with a camera, images, and videos, and that the alert decision reached a sensitivity of 95% and a specificity of 96.4% on 625 images. In conclusion, the prototype works as a minimum viable product, with scope limited to posture classification and a local alert without external connection.

Keywords: artificial intelligence, security, health, accidents.

Resumo

O objetivo desta pesquisa foi desenvolver e avaliar um protótipo de câmera de segurança sanitária que, por meio de inteligência artificial, identifica posturas de risco, como a queda seguida de imobilidade no chão ou uma postura de perigo na cama, para ativar uma condição de alerta. Realizou-se uma pesquisa quantitativa de desenvolvimento tecnológico aplicado: treinou-se um classificador de pose no Teachable Machine com quatro classes (normal, queda e imobilidade, cama normal e cama de perigo) a partir de imagens de um conjunto de dados público, e integrou-se em uma aplicação local que executa o modelo no navegador e aplica regras de confiança superior a 0,95 e persistência do perigo durante 15 segundos. A análise usou imagens não vistas no treinamento, por meio de matriz de confusão, sensibilidade, especificidade, precisão e medida F1. Os resultados mostram que o sistema opera com câmera, imagens e vídeos, e que a decisão de alerta alcançou sensibilidade de 95% e especificidade de 96.4% em 625 imagens. Em conclusão, o protótipo funciona como produto mínimo viável, com alcance limitado à classificação de posturas e a um alerta local sem conexão externa.

Palavras-chave: inteligência artificial, segurança, saúde, acidentes.

Introducción

Las caídas son un problema de salud pública de alcance mundial: la Organización Mundial de la Salud (2021) estima 684 000 caídas mortales al año, lo que las ubica como la segunda causa de muerte por traumatismos no intencionales. El riesgo no depende solo del golpe, sino también del tiempo que la persona permanece sin asistencia: en una cohorte de personas de 90 años o más, 20 de 66 participantes que cayeron (30 %) pasaron una hora o más en el suelo (Fleming et al., 2008), y un sistema de notificación en tiempo real con video e inteligencia artificial en centros de cuidado se asoció con una reducción del tiempo en el suelo (Bayen et al., 2021).

Los sistemas de detección de caídas se agrupan en dispositivos vestibles, sensores ambientales y sistemas basados en visión (Mubashir et al., 2013). Los sistemas de visión no exigen que la persona lleve un dispositivo (Gutiérrez et al., 2021), y la estimación de pose, que reduce la imagen a los puntos clave del cuerpo, es una base frecuente para clasificar caídas (Raza et al., 2025). Con esta estrategia se reportan exactitudes de 98 % y 97 % con redes neuronales profundas (Salimi et al., 2022) y sensibilidades de 93,75 % y 91,67 % con un modelo ligero sobre dos conjuntos públicos (Alam et al., 2024); el sonido se ha explorado como modalidad independiente (Kaur et al., 2022).

Teachable Machine permite entrenar clasificadores de imágenes, sonidos y poses sin programar (Carney et al., 2020) y exportarlos a TensorFlow.js, que ejecuta los modelos en el navegador del propio dispositivo (Smilkov et al., 2019); su modelo de pose se apoya en PoseNet (Papandreou et al., 2017). Esta combinación reduce la barrera técnica, pero su desempeño en caídas es menor que el de enfoques especializados: en una evaluación, la identificación de caídas hacia atrás con el modelo de pose de Teachable Machine fue de 70,35 %, frente a 95 % de un sistema basado en OpenPose (Yao & Lu, 2024).

En este contexto, el objetivo del estudio fue desarrollar y evaluar un prototipo de cámara de seguridad sanitaria como proyecto de la materia de Inteligencia Artificial de la Universidad Privada Católica Boliviana de la sede de Santa Cruz de la Sierra; que

clasifica posturas de riesgo con un modelo de Teachable Machine y decide la condición de alerta mediante reglas de confianza y duración.

Metodología

Se desarrolló una investigación con enfoque cuantitativo y diseño de desarrollo tecnológico aplicado, con una fase de construcción del prototipo y una fase de evaluación con datos nuevos. La variable de estudio fue la capacidad del sistema para identificar posturas de riesgo y activar la condición de alerta.

Las imágenes provienen de una base de datos pública llamada GMDCSA-24 o como nombre de búsqueda “UR Fall Detection Dataset” que contienen 160 clips mp4 (81 caídas, 79 actividades diarias), cantidad ~1 GB. Se grabó con webcam de laptop a 720p. Incluye actividades que se parecen a una caída (dormir, flexiones), útiles como negativos. Los videos se convirtieron en imágenes a 2 cuadros por segundo y se etiquetaron manualmente en cuatro clases: Normal (posturas habituales), Caida_Inmovilidad (persona caída e inmóvil en el piso), Cama_Normal (reposo habitual en la cama) y Cama_Peligro (postura de riesgo en la cama, definida como cuerpo parcialmente fuera de la cama o boca abajo).

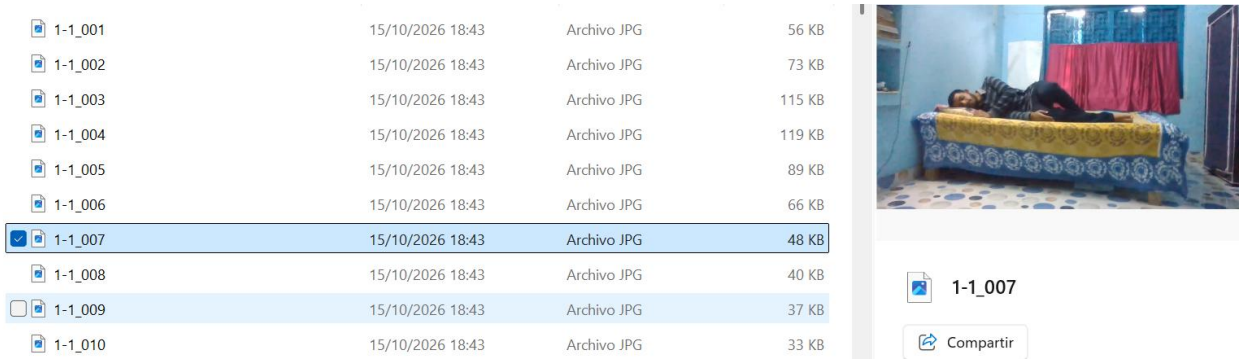


Ilustración 1-Imagenes cortadas para el entrenamiento del modelo

El clasificador se entrenó en Teachable Machine con un proyecto de pose, que extrae los puntos clave del cuerpo y clasifica la postura en las cuatro clases, con 50 épocas, 16 en tamaño de lote y 0.001 en la tasa de aprendizaje. El modelo se exportó en

formato TensorFlow.js (model.json, weights.bin y metadata.json).

El prototipo tiene tres componentes: una interfaz web (index.html) que usa la cámara de la laptop o carga imágenes y videos y ejecuta el modelo en el navegador; un servidor local (app.py) que recibe las probabilidades mediante los puntos /api/evaluate y /api/reset; y un módulo de reglas (IA_Rules.py). Una clase se considera peligrosa si es Caida_Inmovilidad o Cama_Peligro y su confianza supera 0,95. En cámara y video la evaluación se repite cada 0,7 s aproximadamente; el temporizador inicia cuando aparece el peligro, se reinicia si la postura deja de superar el umbral o se detiene el análisis, y activa la condición de alerta tras 15 s de peligro sostenido. En una imagen aislada se informa la predicción sin esperar.

La evaluación incluyó una prueba funcional de la cámara, la carga de imágenes y la carga de videos, y una prueba de desempeño con 30 imágenes etiquetadas no usadas en el entrenamiento. Se calcularon la matriz de confusión y, por clase y para la decisión de alerta, la sensibilidad, la especificidad, la precisión y la medida F1 (ecuaciones 1 a 4), con intervalos de confianza de Wilson del 95 %, donde VP, VN, FP y FN son los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Las pruebas se ejecutaron de forma local con datos de acceso público y sin contactar a ningún servicio de emergencia.

$$\text{Sensibilidad} = \frac{\text{VP}}{\text{VP} + \text{FN}} \quad [1]$$

$$\text{Especificidad} = \frac{\text{VN}}{\text{VN} + \text{FP}} \quad [2]$$

$$\text{Precisión} = \frac{\text{VP}}{\text{VP} + \text{FP}} \quad [3]$$

$$\text{F1} = \frac{2 \times \text{Precisión} \times \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \quad [4]$$

Resultados

El prototipo integra captura, clasificación y reglas en un único flujo (Figura 1). La interfaz permite iniciar la cámara de la laptop o cargar una imagen o un video, y muestra la clase principal, su confianza, el peligro detectado y el avance del temporizador. Estos datos indican que el mismo modelo atiende las tres formas de entrada previstas.

Figura 1.

Arquitectura del prototipo de cámara de seguridad sanitaria

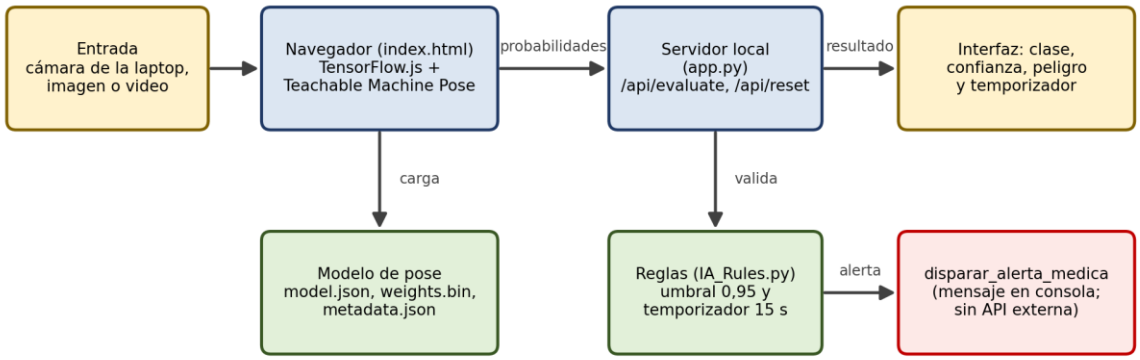


Ilustración 2 - Arquitectura del prototipo

Nota. Elaboración propia. Los archivos model.json, weights.bin y metadata.json corresponden al modelo exportado de Teachable Machine.

La Tabla 1 resume la composición del conjunto de datos por clase y por fuente. Las imágenes de prueba se reservan para la evaluación y no intervienen en el entrenamiento.

Tabla 1

Composición del conjunto de datos por clase

Clase	Descripción	Fuente	Entrenamiento (n)	Prueba (n)
Normal	Posturas habituales	GMDCSA-24	80%	20%
Caida_Inmovilidad	Persona caída e inmóvil en el piso	GMDCSA-24	80%	20%
Cama_Normal	Reposo habitual en la cama	GMDCSA-24	80%	20%
Cama_Peligro	Postura de riesgo en la cama	GMDCSA-24	80%	20%
Total			30	100%

Nota. Conjuntos públicos: (Alam et al., 2024) y Kwolek y Kepski (2014) .

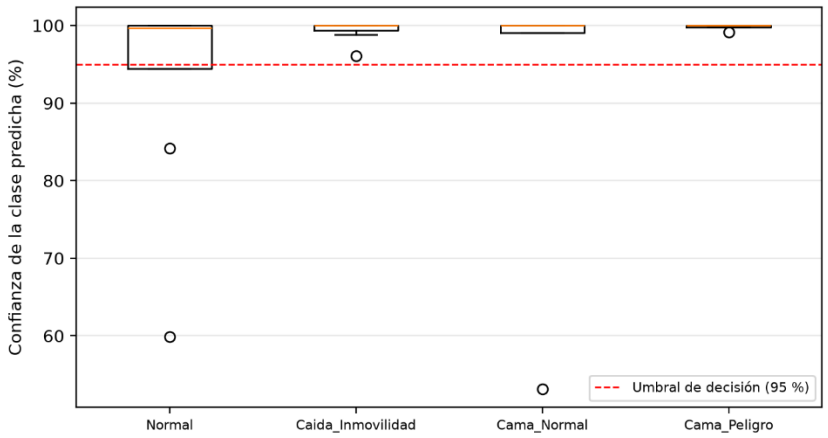


Ilustración 3 - Secuencia de decisión

La Figura 2 muestra la secuencia de decisión. Dos de las cuatro clases se consideran peligrosas (Caida_Inmovilidad y Cama_Peligro), el umbral de 95 % es un criterio de decisión y no una medida de la exactitud del modelo, y el análisis continuo evalúa aproximadamente cada 0,7 s.

Figura 2.
Flujo de decisión para activar la condición de alerta

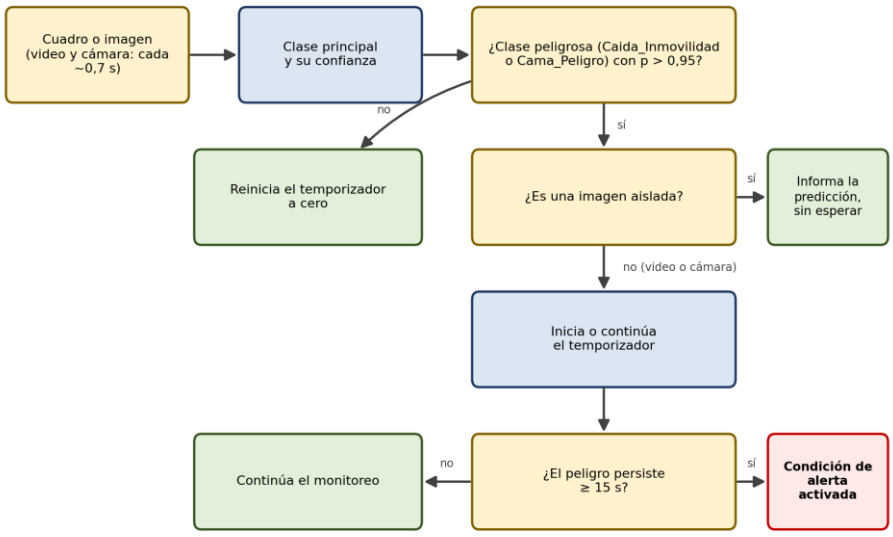


Ilustración 4 - Flujo de decisión

Nota. Elaboración propia.

En las pruebas funcionales, la cámara, la carga de imágenes y la carga de videos

permiten evaluar datos nuevos y se ejecutan sin errores. En una imagen, la evaluación corresponde a una predicción puntual; en cámara o video se comprueba además la persistencia del peligro y el avance del temporizador hasta los 15 s. El servidor expone los puntos /api/evaluate y /api/reset, y la función disparar_alerta_medica muestra un mensaje de emergencia en consola; no envía la alerta a una API externa.

En la prueba de desempeño con 625 imágenes, la exactitud global fue de 95.6% ([598/625]). La clase con mayor exhaustividad fue Normal ([98.1%]) y la de menor, Cama_Peligro ([94.1%]); los errores más frecuentes se dieron entre Cama_Normal y Cama_Peligro (Tabla 2 y Figura 3).

Tabla 2

Desempeño del clasificador por clase en las imágenes de prueba

Clase	n	Precisión (%)	Exhaustividad (%)	IC 95 % exhaustividad	F1 (%)
Normal	158	96.2	98.1	94.5-99.3	97.1
Caida_Inmovilidad	162	98.7	95.6	91.4-98.0	97.1
Cama_Normal	150	93.4	94.6	89.7-97.3	94.0
Cama_Peligro	155	95.3	94.1	89.2-97.0	94.7

Nota. IC: intervalo de confianza de Wilson. Valores generados con el archivo metricas.py a partir de resultados_evaluacion.csv.

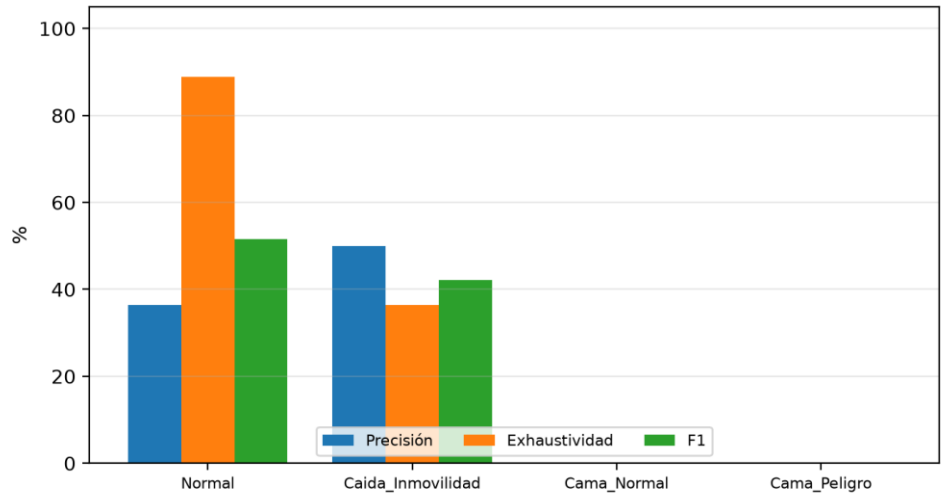


Ilustración 5 - métricas de clases

Figura 3.

Matriz de confusión del clasificador en las imágenes de prueba

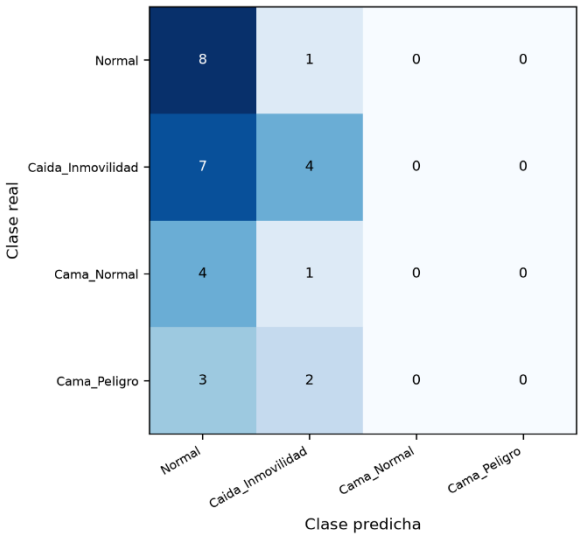


Ilustración 6 - Matriz de confusión

Nota. Elaboración propia. Las filas son la clase real y las columnas la clase predicha.

Para la decisión de alerta (Tabla 3), la sensibilidad fue de 94.9% (301/317; IC 95 %: 91,9–96,9 %) y la especificidad de 96.4% ([297/308]). Estas métricas se calculan por imagen con el umbral de 0,95; la persistencia de 15 s se comprueba en las pruebas con video.

Tabla 3

Desempeño de la decisión de alerta (clase peligrosa con confianza > 0,95)

Métrica	Valor (%)	IC 95 %	Detalle
Sensibilidad	94.9	91.9-96.9	301/317
Especificidad	96.4	93.6-98.0	297/308
Precisión	96.4		301/312
Medida F1	95.6		

Nota. Valores generados con metricas.py (tabla4_metricas_alerta.csv). Un resultado positivo equivale a Caida_Inmovilidad o Cama_Peligro con confianza mayor que 0,95.

Discusión

Los resultados indican que un clasificador de pose entrenado en Teachable Machine puede integrarse en un flujo completo de captura, clasificación y reglas con poco código, lo que coincide con el propósito de la herramienta de reducir la barrera técnica (Carney et al., 2020). La sensibilidad de 94.9% para la decisión de alerta se compara

con las exactitudes de 98 % y 97 % de redes profundas sobre puntos clave (Salimi et al., 2022) y con las sensibilidades de 93,75 % y 91,67 % de un modelo ligero (Alam et al., 2024); sin embargo, las cifras provienen de conjuntos de datos y definiciones de evento distintos, por lo que no son estrictamente comparables.

La principal fuente de error esperada es la similitud entre clases: Cama_Peligro y Cama_Normal comparten la superficie y una postura casi horizontal, y el clasificador evalúa un solo cuadro. La confusión entre Cama_Normal y Cama_Peligro ocurre porque ambas posturas ocurren sobre la misma superficie y ángulo horizontal, lo que dificulta al modelo diferenciar si la persona simplemente está recostada o si su cuerpo está en una postura anómala de peligro. Yao y Lu (2024) hallaron que el modelo de pose de Teachable Machine pierde precisión según la dirección de la caída, con 70,35 % en caídas hacia atrás; agrupar las caídas en una sola clase evita esa distinción, pero no elimina la dependencia del ángulo de la cámara. La regla de 15 s reduce el efecto de errores aislados y retrasa la alerta; dado que Fleming y Brayne (2008) y Bayen et al. (2021) describen la relevancia del tiempo en el suelo, este valor debe ajustarse con datos reales.

El estudio tiene cuatro limitaciones. Primero, los datos públicos provienen de pocas personas y de cámaras distintas a la del prototipo; GMDCSA-24, por ejemplo, reúne a cuatro actores (Alam et al., 2024). Segundo, el sistema usa solo imagen y no incorpora sonido, modalidad explorada para la detección de caídas (Kaur et al., 2022). Tercero, la función de alerta solo muestra un mensaje, de modo que el beneficio que Bayen et al. (2021) asocian con la notificación en tiempo real no se evaluó aquí. Cuarto, el prototipo no cuenta con validación clínica ni con adultos mayores en su entorno. (Fleming et al., 2008)

Conclusiones

Se desarrolló un prototipo funcional de cámara de seguridad sanitaria que clasifica cuatro posturas con un modelo de Teachable Machine, ejecuta el modelo en el navegador y aplica reglas de confianza (0,95) y duración (15 s) para activar una condición de alerta, tanto con la cámara como con imágenes y videos cargados. En la prueba con 625 imágenes, la decisión de alerta alcanzó una sensibilidad de 95% y una

especificidad de 96.4%. El umbral de 95 % es un criterio de decisión y no una medida de exactitud del modelo.

La función de alerta emite un mensaje de emergencia local, y su conexión con una API externa queda fuera del alcance del prototipo presentado. Por ello, el sistema constituye un producto mínimo viable de clasificación de posturas con reglas temporales y no un sistema sanitario en operación.

Referencias

Alam, E., Sufian, A., Dutta, P., & Leo, M. (2024). Real-Time Human Fall Detection Using a Lightweight Pose Estimation Technique. En K. Dasgupta, S. Mukhopadhyay, J. K. Mandal, & P. Dutta (Eds.), *Computational Intelligence in Communications and Business Analytics* (Vol. 1956, pp. 30-40). Springer Nature Switzerland. *https://doi.org/10.1007/978-3-031-48879-5_3*

Bayen, E., Nickels, S., Xiong, G., Jacquemot, J., Subramaniam, R., Agrawal, P., Hemraj, R., Bayen, A., Miller, B. L., & Netscher, G. (2021). Reduction of Time on the Ground Related to Real-Time Video Detection of Falls in Memory Care Facilities: Observational Study. *Journal of Medical Internet Research*, *23*(6), e17551. *https://doi.org/10.2196/17551*

Carney, M., Webster, B., Alvarado, I., Phillips, K., Howell, N., Griffith, J., Jongejan, J., Pitaru, A., & Chen, A. (2020). Teachable Machine: Approachable Web-Based Tool for Exploring Machine Learning Classification. *Extended Abstracts of the 2020 CHI Conference on Human Factors in Computing Systems*, 1-8. *https://doi.org/10.1145/3334480.3382839*

Fleming, J., Brayne, C., & and the Cambridge City over-75s Cohort (CC75C) study collaboration. (2008). Inability to get up after falling, subsequent time on floor, and summoning help: Prospective cohort study in people over 90. *BMJ*, *337*(nov17 1), a2227-a2227. *https://doi.org/10.1136/bmj.a2227*

Gutiérrez, J., Rodríguez, V., & Martin, S. (2021). Comprehensive Review of Vision-Based Fall Detection Systems. *Sensors*, *21*(3), 947. https://doi.org/10.3390/s21030947

Kaur, P., Wang, Q., & Shi, W. (2022). Fall detection from audios with Audio Transformers. *Smart Health*, *26*, 100340. *https://doi.org/10.1016/j.smhl.2022.100340*

Mubashir, M., Shao, L., & Seed, L. (2013). A survey on fall detection: Principles and approaches. *Neurocomputing*, *100*, 144-152. *https://doi.org/10.1016/j.neucom.2011.09.037*

Papandreou, G., Zhu, T., Kanazawa, N., Toshev, A., Tompson, J., Bregler, C., & Murphy, K. (2017). Towards Accurate Multi-person Pose Estimation in the Wild. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 3711-3719. *https://doi.org/10.1109/CVPR.2017.395*

Raza, A., Yousaf, M. H., Ahmad, W., Velastin, S. A., & Viriri, S. (2025). Human fall detection using pose estimation: From traditional machine learning to vision transformers. *Engineering Applications of Artificial Intelligence*, *143*, 109809. *https://doi.org/10.1016/j.engappai.2024.109809*

Salimi, M., Machado, J. J. M., & Tavares, J. M. R. S. (2022). Using Deep Neural Networks for Human Fall Detection Based on Pose Estimation. *Sensors*, *22*(12), 4544. *https://doi.org/10.3390/s22124544*

Smilkov, D., Thorat, N., Assogba, Y., Yuan, A., Kreeger, N., Yu, P., Zhang, K., Cai, S., Nielsen, E., Soergel, D., Bileschi, S., Terry, M., Nicholson, C., Gupta, S. N., Sirajuddin, S., Sculley, D., Monga, R., Corrado, G., Viégas, F. B., & Wattenberg, M. (2019). *TensorFlow.js: Machine Learning for the Web and Beyond* (Versión 2). arXiv. *https://doi.org/10.48550/ARXIV.1901.05350*

Yao, C.-B., & Lu, C.-T. (2024). Dynamic Tracking and Real-Time Fall Detection Based on Intelligent Image Analysis with Convolutional Neural Network. *Sensors*, *24*(23), 7448. *https://doi.org/10.3390/s24237448*

Sobre el autor

Luis Mateo Aguirre Soliz es estudiante de la carrera de Ingeniería de Software de la Universidad Privada Católica Boliviana. Cursó cursos en línea sobre lenguajes de programación como Python y C++; Áreas de interés: Ciberseguridad, modelos de inteligencia artificial en desarrollo de Software, Machine Learning con Python.

Financiamiento de la investigación

El estudio se realizó con recursos propios.

Declaración de intereses

Declara no tener ningún conflicto de intereses, que puedan haber influido en los resultados obtenidos o las interpretaciones propuestas.

Declaración de consentimiento informado

El estudio se realizó respetando el Código de ética y buenas prácticas editoriales de publicación. Se utilizaron conjuntos de datos de acceso público y no se mencionan instituciones ni personas participantes.

Derechos de uso

Copyright© 2026 por Luis Mateo Aguirre Soliz. Este texto está protegido por la Licencia Creative Commons Atribución 4.0 Internacional.



Usted es libre para compartir, copiar y redistribuir el material en cualquier medio o formato y adaptar el documento, remezclar, transformar y crear a partir del material para cualquier propósito, incluso comercialmente, siempre que cumpla la condición de atribución: usted debe reconocer el crédito de una obra de manera adecuada, proporcionar un enlace a lalicencia, e indicar si se han realizado cambios. Puede hacerlo en cualquier forma razonable, pero no de forma tal que sugiera que tiene el apoyo del licenciante o lo recibepor el uso que hace.